Предикција нивоа зависности од мобилних телефона код тинејџера

Страхиња Ђукић Е2 89/2025, Николина Роган Е2 96/2025

1. Дефиниција проблема

Потребно је анализирати податке о коришћењу мобилних телефона код тинејџера и испитати да ли постоји повезаност између нивоа зависности и навика коришћења телефона. Извршићемо предикцију нивоа зависности од мобилних телефона помоћу социолошких и здравствених фактора, као и података о коришћењу телефона. Такође, даћемо одговор на питање који то фактори највише утичу на појаву зависности код тинејџера.

2. Мотивација проблема рјешаваног у пројекту

Зависност од мобилних телефона представља све већи проблем међу млађом популацијом и може негативно утицати на њихове навике, успјех у школи и опште здравље. Разумијевање образаца понашања повезаних са овом појавом омогућава раније препознавање ризичних случајева, што може бити од значаја за родитеље и образовне институције. Закључци истраживања могу помоћи у развоју апликација и алата за "дигитално благостање" који су прилагођени специфичним навикама корисника.

3. Релевантна литература

3.1 Predicting Smartphone Addiction Levels with K-Nearest Neighbors Using User Behavior Patterns (линк)

Тема: примјена KNN алгоритма како би се предвидио ниво зависности од паметних телефона. Аутори истражују његову ефикасност, јер се у другим студијама чешће примјењују други алгоритми. Циљ рада није само предикција, већ и анализа фактора који највише утичу на појаву зависности.

Методологија: подаци су најприје претпроцесирани, избачене су непостојеће вриједности, категорички подаци су трансформисани уз помоћ one-hot endcodinga. Коришћене су матрице корелације, како би се одабрали значајни атрибути и коришћена је Z-score стандардизација и Min-max нормализација. Након претпроцесирања је коришћен KNN са еуклидским растојањем како би се одредио степен зависности корисника. Утврђено је да је оптимална вриједност k параметра 5.

Подаци: скуп података садржи **3.300** уноса о понашању корисника. Укључујући модел уређаја, оперативни систем, вријеме коришћења апликација (мин/дан), вријеме укљученог екрана, пражњење батерије (mAh/дан), број инсталираних апликација, потрошњу података, старост, пол и класу понашања корисника (ниво зависности 1-5).

Евалуација: подаци су подијељени на тренинг и тест скуп у односу 80 : 20. Рјешење је евалуирано на тест скупу и модел је достигао **тачност** од 95%. Такође, коришћена је **F1 мјера** и достигла је до 0.96 за двије од пет посматраних класа.

Закључак: вријеме коришћења апликација и пражњење батерије су главни фактори за предвиђање зависности, док демографски подаци попут пола и старости немају никакав утицај. Рад потврђује

ефикасност KNN алгоритма, и препоручује проширивање скупа атрибута што ћемо у нашем раду и учинити.

3.2 Discovery of factors associated with smartphone addiction among high school adolescents: Using machine learning and network analysis [линк]

Тема рада: проналажење кључних фактора који утичу на зависност од паметних телефона код средњошколаца. У раду се користе и упоређују различити модели машинског учења како би се дошло до најбољих резултата.

Методологија: у раду се користе модели машинског учења за предикцију и мрежна анализа за разумијевање веза између атрибута. Тестирано је девет алгоритама: логистичка регресија, стабло одлучивања, Random Forest, SVM, XGBoost, KNN, MLP, Lasso и LightGBM. **XGBoost** је одабран као најбољи јер је постигао највећу прецизност у предвиђању зависности. Коришћене су **SHAP вриједности** како би се рангирао значај 20 варијабли и разумио њихов појединачни допринос моделу.

Подаци: укупно **14.036** средњошколаца узраста од 15 до 18. Подаци су прикупљени путем анонимне анкете и подијељени на тест и тренинг скуп у односу 70 : 30. Користи се 20 атрибута попут пола, старости, статуса родитеља, али и психолошки фактори попут нивоа анксиозности, депресије , учења под притиском, усамљености, самоповрјеђивања...

Евалуација рјешења: коришћене су стандардне метрике за проблеме класификације, попут **AUC** (површина испод ROC криве), **тачности**, **прецизности**, **одзива** и **F1-score**.

Закључак: у нашем пројекту ћемо користити **XGBoost** модел и **SHAP** интерпретацију, јер су се овом раду најбоље показали. Као и аутори рада, ми нећемо гледати само вријеме проведено уз екран, већ ћемо узети у обзир и животне факторе (нпр. ниво анксиозности), како бисмо тачније открили ко је заиста у ризику од зависности.

3.3 Prediction of Problematic Smartphone Use: A Machine Learning Approach (линк)

Тема рада: предвиђање нивоа зависности од мобилних телефона употребом метода машинског учења, ослањајући се на податке о употреби уређаја (нпр. вријеме проведено на телефону). Циљ је био да се покаже да се и на основу ових података може предвидјети зависност, с обзиром да се већина постојећих радова ослањала на психолошке факторе и свакодневне навике приликом предвиђања.

Методологија: користе се и упоређују **Decision tree**, **Random Forest** и **XGBoost** алгоритми. Користи се **5-fold cross-validation** за сваки од модела, као и Grid Search за подешавање хиперпараметара.

Подаци: **29.712** учесника из Јужне Кореје је попуњавало анкету од 180 питања, од којих је за истраживање искоришћено 27, као што су: године, пол, занимање, фреквенција употребе радним данима и викендом, вријеме проведено пратећи различите садржаје, као и информације о новцу потрошеном на коришћење различитих врста садржаја (новине, вијести, игрице, …).

Евалуација рјешења: скуп података је подијељен на тренинг / тест скуп у односу 70 : 30. Коришћене су метрике **тачности** и **одзива**. Највећу тачност на тест скупу је постигао Random Forest (82,59%), док је најмању тачност постигло стабло одлучивања (74,56%).

Закључак: резултати су потврдили да су подаци о обрасцима коришћења апликација и подаци о мјесечној потрошњи на различите садржаје довољни да се идентификује зависност. У нашем пројекту

ћемо, по угледу на овај рад, поред података о свакодневним навикама и психолошким карактеристикама учесника узети у обзир и објективне податке о употреби уређаја.

4. Скуп података

За израду пројекта користићемо постојећи, синтетички скуп података који је преузет са платформе *Kaggle* (**https://www.kaggle.com/datasets/sumedh1507/teen-phone-addiction**) који садржи податке о дигиталним навикама, психолошким факторима и животном стилу тинејџера. Скуп се састоји од 3**000 инстанци** и **25 атрибута**. Циљно обиљежје је *Addiction_Level* које представља ниво зависности од телефона и изражено је у опсегу од 0 до 10 (континуалне вриједности). Атрибути из скупа података који описују интензитет употребе телефона су, дневно вријеме проведено на телефону, број провјеравања телефона и вријеме проведено на телефону прије спавања, а у обзир се узима и вријеме проведено на друштвеним мрежама и игрицама. Такође, разматрају се и психолошки фактори и животне навике као што су ниво анксиозности, депресије и самопоуздања, као и број сати сна и физичких активности.

5. Методологија

Након учитавања и претпроцесирања података, анализираћемо кључне атрибуте попут времена коришћења телефона, броја откључавања телефона и социјалне анксиозности. У току фазе претпроцесирања категоричке атрибуте име и локација ћемо уклонити јер немају значај за нашу анализу, а за атрибуте као што је пол ћемо користити **One hot encoding** методу. С обзиром да су KNN и MLP осјетљиви на размјеру података, користићемо **Standard scaler** стандардизацију. Такође, имајући у виду да је скуп података тако конструисан да се већина вриједности у колони за ниво зависности налази у опсегу 9 – 10, увешћемо тежинску регресију додјељивањем већих тежина узорцима са нижим „скором“ зависности. За предвиђање зависности упоредићемо **KNN**, **XGBoost**, **MLP NN** и **линеарну регресију** како бисмо обезбиједили оптималне перформансе. Користићемо корелациону матрицу за испитивање повезаности атрибута и **SHAP** вриједности за прецизно утврђивање појединачног доприноса сваког атрибута финалној предикцији.

6. Метод евалуације

С обзиром да наш скуп података садржи само 3000 инстанци, користићемо иницијалну подјелу података 70/30 на тренинг и тест скуп и на тренинг скуп ћемо додатно примијенити **k-fold cross-validation.** Успјешност изабраних алгоритама мјерићемо кроз четири стандардне метрике **RMSE, MAE**, $\mathbf{R^2}$ и прилагођени $\mathbf{R^2}$.